

اکوسیستم هوش مصنوعی گوگل

از مدل‌های پایه جمنای تا ارکستراسیون ایجنتیک با Antigravity

جلسه اول | آپدیت ۲۰۲۶ | بررسی جامع ابزارها و مدل‌ها

برنامه جامع جلسه اول (۴ ساعت)

ساعت دوم

چشم انداز مدل های هوش
مصنوعی ۲۰۲۶ (مقایسه، هزینه،
کانتکست)

ساعت چهارم

معرفی Antigravity و آماده سازی
برای توسعه Agent-First

ساعت اول

تشریح کامل اکوسیستم گوگل
(Vertex, AI Studio, Gemini)

ساعت سوم

بررسی تفاوت های اکوسیستمی
(Gems vs GPTs, RAG,
Memory)

بخش اول: اکوسیستم ابری گوگل

زیرساخت‌هایی که مدل‌های هوشمند را در دسترس قرار می‌دهند

Google Vertex AI (سطح سازمانی)

Google Vertex AI cloud architecture diagram abstract glowing lines dark theme

پلتفرم یادگیری ماشین (ML) قدرتمند گوگل کلود برای سازمان‌های بزرگ (Enterprise).

امنیت و حریم خصوصی: داده‌های ارسالی به Vertex هرگز برای آموزش مدل‌های پایه گوگل (Training) استفاده نمی‌شوند.

امکان استقرار (Deployment) مدل‌های اپن‌سورس (مثل Llama 4 یا DeepSeek V4) در زیرساخت امن گوگل.

ابزارهای پیشرفته برای Fine-tuning و نظارت (MLOps) بر مدل‌ها در مقیاس بالا.

Google AI Studio (سطح توسعه‌دهنده)

محیطی سبک، رایگان و بهینه‌سازی شده برای توسعه‌دهندگان (Developers) جهت نمونه‌سازی سریع (Prototyping).

- بهترین مکان برای دریافت **API Key** و تست پرامپت‌ها قبل از پیاده‌سازی در کد.
- رابط کاربری ساده برای مقایسه مدل‌ها (مثل Gemini 3.1 Pro با Flash).
- امکان تنظیم دقیق پارامترها (Temperature, Top-K) و تولید خودکار کد پایتون یا cURL از پرامپت‌های تست شده.

Gemini UI (سطح کاربر نهایی)



افزونه‌ها (Extensions)

اتصال بومی به سرویس‌های گوگل مثل
YouTube، Maps و Flights برای ارائه
پاسخ‌های کاربردی و لحظه‌ای در دل چت.



یکپارچگی با Workspace

دسترسی مستقیم جمعی به Google Drive،
Docs، Sheets و Gmail برای استخراج
اطلاعات و انجام تسک‌های اداری.



رابط چت (Chat Interface)

محیطی شبیه به ChatGPT برای تعامل
روزمره. پشتیبانی از ورودی‌های چندوجهی
(صدا، تصویر، فایل) با سرعت بالا.

NotebookLM: دستیار پژوهشی و RAG بدون کد



📖 **مغز دوم شما:** ابزاری قدرتمند برای بارگذاری اسناد پروژه، PDF ها و کدهای منبع.

🔗 **ارجاع دقیق (Citations):** پاسخ‌ها منحصراً بر اساس منابع شما تولید شده و شماره خط یا پاراگراف منبع را نشان می‌دهد.

🎧 **Audio Overviews:** تولید پادکست‌های گفتگو محور از مستندات خسته‌کننده.


⚡ **برای برنامه‌نویسان، این بهترین ابزار برای درک معماری پروژه‌های Legacy و کدبیس‌های ناشناخته است.**

مقدمه‌ای بر Antigravity

توسعه در عصر Agentic

در حالی که AI Studio برای پرامپت زدن است، **Antigravity** پلتفرم رسمی گوگل برای ساخت، دیپلوی و مدیریت ایجنت‌های خودمختار است.

این سیستم شامل ابزارهای CLI برای اجرای دستورات در ترمینال و UI برای نظارت بر فرآیند تفکر (Reasoning) ایجنت‌هاست. (در جلسه دوم عمیقاً به آن می‌پردازیم).



بخش دوم: چشم انداز مدل های AI در ۲۰۲۶

مقایسه غول های تکنولوژی: هزینه، کانتکست و کارایی

پرچمداران بازار: نبرد مدل‌های سنگین

GPT-5.5 & Claude Opus 4.8

GPT-5.5: مدل پرچمدار OpenAI با کانتکست ۱ میلیون توکنی، بسیار هوشمند اما با هزینه بالا.

Claude Opus 4.8: شاهکار Anthropic، با دقت بالا در کدنویسی و عدم توهم، محبوب‌ترین گزینه برای برنامه‌نویسان وسواسی.

Gemini 3.1 Pro (Google)

قدرتمندترین مدل گوگل با پنجره کانتکست عظیم ۲ میلیون توکنی. بی‌رقیب در پردازش مالتی‌مودال (ویدیو و کدبیس‌های بزرگ به صورت یکجا). معماری استدلال (Reasoning) آن در سال ۲۰۲۶ ارتقای چشمگیری داشته است.

لیدرهای بهره‌وری (Cost/Efficiency)



🚀 **DeepSeek V4 Pro/Flash**: شگفتی‌ساز چینی. مدل‌هایی که هوش در سطح GPT-4 را با هزینه‌ای تا ۵۰ برابر کمتر ارائه می‌دهند. بازیگر اصلی در سیستم‌های پرمصرف.

⚡ **Gemini 3.1 Flash**: پاسخ گوگل به نیاز سرعت. مدلی سبک و بسیار سریع که برای تسک‌های روتین، خلاصه‌سازی و RAG در حجم بالا ایده‌آل است.

⚖️ **استراتژی Routing**: در برنامه‌نویسی ایجننتیک ۲۰۲۶، تسک‌های سخت به مدل‌های Pro و تسک‌های ساده (مثل فرمت کردن JSON) به مدل‌های Flash یا DeepSeek سپرده می‌شود.

انقلاب کانتکست ویندو (Context Window)

چرا کانتکست مهم است؟

دو میلیون توکن یعنی شما می‌توانید کل کدهای یک پروژه بزرگ (شامل ده‌ها فایل)، به همراه مستندات آن را در یک پرامپت ارسال کنید.

مدل تمام وابستگی‌ها (Dependencies) را در حافظه کوتاه مدت خود درک می‌کند، که این امر نیاز به راه‌اندازی سیستم‌های پیچیده RAG را برای پروژه‌های متوسط به شدت کاهش می‌دهد.

+2M

Tokens (Gemini 3.1 Pro)

جدول مقایسه API مدل‌های برتر (تیر ۲۰۲۶)

نام مدل	سازنده	حجم کانتکست	هزینه ورودی (۱M توکن)	هزینه خروجی (۱M توکن)
Gemini 3.1 Pro	Google	۲,۰۰۰,۰۰۰	\$۲.۰۰	\$۱۲.۰۰
GPT-5.5	OpenAI	۱,۰۰۰,۰۰۰	\$۵.۰۰	\$۳۰.۰۰
Claude Opus 4.8	Anthropic	۱,۰۰۰,۰۰۰	\$۵.۰۰	\$۲۵.۰۰
Claude Sonnet 4.6	Anthropic	۱,۰۰۰,۰۰۰	\$۳.۰۰	\$۱۵.۰۰
Gemini 3.1 Flash	Google	۱,۰۰۰,۰۰۰	\$۱.۵۰	\$۹.۰۰
DeepSeek V4 Pro	DeepSeek	۱,۰۰۰,۰۰۰	\$۰.۴۴	\$۰.۸۷

بخش سوم: تفاوت‌های اکوسیستمی

قابلیت‌های متمایزی که فراتر از قدرت خام مدل‌ها هستند

شخصی سازی: Gems در برابر رقبا



Google Gems

متخصص‌های شخصی‌سازی شده در Gemini
UI. مزیت اصلی آن‌ها اتصال یکپارچه با
اکوسیستم فایل‌های Google Drive و
Workspace است.



Claude Projects

محیطی ایزوله برای آپلود کدهای پروژه و
تعیین دستورالعمل‌های خاص. ایده‌آل برای
حفظ کانتکست در توسعه تیمی.



OpenAI GPTs

امکان ساخت ربات‌های کاستوم با
Action‌های پیچیده و دسترسی به API‌های
خارجی. دارای فروشگاه متمرکز (GPT Store).

مدیریت حافظه (Chat Memory)



هر دو پلتفرم ChatGPT و Gemini اکنون دارای قابلیت **Memory** هستند. 🧠

این ویژگی به مدل اجازه می‌دهد ترجیحات، سبک کدنویسی و اطلاعات مربوط به پروژه‌های شما را در طول زمان و در چت‌های مختلف به خاطر بسپارد. ⚙️

کنترل کاربر: شما می‌توانید صراحتاً به مدل بگویید چیزی را به خاطر بسپارد یا از بخش تنظیمات، حافظه را پاک کنید. 👤

Grounding بومی در برابر RAG

اختصاصی

Native Grounding (گوگل):

چمنای می‌تواند در لحظه به موتور جستجوی گوگل متصل شود تا پاسخ‌های خود را با داده‌های آنلاین اعتبارسنجی کند (جلوگیری از توهم).

Custom RAG (توسعه‌دهندگان):

برای داده‌های خصوصی سازمان (دیتابیس‌ها، کدهای سرور)، ما باید با استفاده از Vector Database ها و فریم‌ورک‌هایی مثل LangChain، سیستم RAG خود را بسازیم تا مدل به داده‌های اینترنت ما دسترسی پیدا کند.



دستیارهای کدنویسی: Antigravity در برابر رقبا



🔄 **OpenAI Codex / Copilot**: تمرکز بر تکمیل خودکار کد (Auto-complete) در درون ادیتور. رویکردی واکنشی (Reactive).

📄 **Claude Artifacts**: تولید سریع ال و کدهای مستقل در یک پنجره کناری قابل اجرا. عالی برای فرانت‌اند.

🤖 **Google Antigravity**: رویکرد کاملاً **Agentic**. ایجنت در ترمینال شما زندگی می‌کند، می‌تواند فایل بسازد، پکیج نصب کند، تست ران کند و در صورت خطا، خودش مشکل را سرچ و دیباگ کند (Proactive).

مسیر تکامل برنامه‌نویسان در عصر هوش مصنوعی

نسل دوم (۲۰۲۴)

دستیارهای IDE (مثل Copilot) و
استفاده از RAG برای
کانتکست‌دهی.

نسل چهارم (۲۰۲۶+)

توسعه Agentic. مدیریت
ارکستراسیون ایجنت‌های
خودمختار با Antigravity.

نسل اول (۲۰۲۳)

چت‌بات‌ها به عنوان مشاور.
کپی/پیست کردن کد از
ChatGPT.

نسل سوم (۲۰۲۵)

مدل‌های با کانتکست عظیم (۲
میلیونی) و قابلیت درک کل پروژه
یکجا.

پایان جلسه اول

شما اکنون با جغرافیای کامل مدل‌های ۲۰۲۶ و جایگاه گوگل آشنا هستید.

...در جلسه دوم وارد ترمینال می‌شویم >

Image Sources

<https://images.ctfassets.net/dkao92vrypgx/6zlo4lM14vHpRl6r2py5h2/af064c8437ba50c2ca89aab6e502a90f/architecture.png>

Source: nimstrata.com



<https://blog-cdn.skywork.ai/wp-content/uploads/2025/10/451f169f8b3446a88b45d8942c9d4aa2.jpg>

Source: skywork.ai



<https://felloai.com/wp-content/uploads/2026/06/what-is-notebooklm.jpg>

Source: felloai.com



https://miro.medium.com/v2/resize:fit:1200/0*vwPwLk3LvH4udBLH.jpg

Source: medium.com



[https://substackcdn.com/image/fetch/\\$s_!SsjB!,f_auto,q_auto:good,fl_progressive:steep/https%3A%2F%2Fsubstack-post-media.s3.amazonaws.com%2Fpublic%2Fimages%2Fe23a1645-664f-4896-a6c7-36664e0c84de_1837x976.jpeg](https://substackcdn.com/image/fetch/$s_!SsjB!,f_auto,q_auto:good,fl_progressive:steep/https%3A%2F%2Fsubstack-post-media.s3.amazonaws.com%2Fpublic%2Fimages%2Fe23a1645-664f-4896-a6c7-36664e0c84de_1837x976.jpeg)

Source: gradientflow.substack.com



<https://static.vecteezy.com/system/resources/thumbnails/075/426/145/small/glowing-brain-with-neural-network-connections-in-a-futuristic-dark-room-photo.jpeg>

Source: www.vecteezy.com



Image Sources

<https://sudoall.com/wp-content/uploads/2026/04/context-graphs-knowledge-nodes.jpeg>

Source: sudoall.com



<https://imgproxy.divecdn.com/kCge1hXLR9Yglb4agli-P01AyIfNnqiJ20hMEF7sxMA/g:ce/rs:fill:1200:675:1/Z3M6Ly9kaXZlc2l0ZS1zdG9yYWdlL2RpdmVpbWFnZS9HZXR0eUltYWdlcy0yMjQwNDQ3MzU1LmpwZW==.webp>

MjQwNDQ3MzU1LmpwZW==.webp

Source: www.channeldive.com

